Implementacja algorytmu Nearest Neighbours

Projekt wykonali: Jakub Płoskonka, Rafał Nowicki
Prowadzący: dr inż. Marcin Pietroń
Data wykonania: 10.01.2025r.

Spis treści

Algorytm Nearest Neighbours (NN)

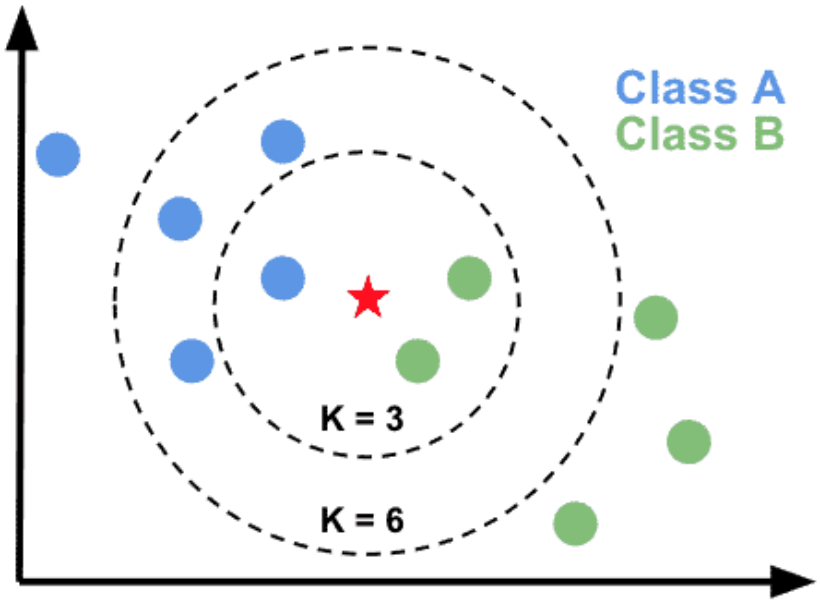

Rys 1 Wykres klasyfikacji nowej danej wg algorytmu k-NN

Zasada działania:

1. **Zbiór danych**:
    - Mamy zbiór danych treningowych, w którym każdy element posiada cechy (wektor cech) oraz klasę lub wartość docelową.
2. **Nowy element**:
    - Dla nowego elementu algorytm oblicza odległość między nim a wszystkimi elementami zbioru treningowego.
3. **Znajdowanie najbliższych sąsiadów**:
    - Algorytm wybiera **k najbliższych sąsiadów** (najczęściej według metryki euklidesowej lub innych miar odległości).
4. **Decyzja o klasyfikacji lub wartości**:
    - **Klasyfikacja**: Nowemu elementowi przypisuje się klasę, która najczęściej występuje wśród sąsiadów.
    - **Regresja**: Wynik dla nowego elementu jest średnią wartości jego sąsiadów.

Cel projektu

Implementacja algorytmu Nearest Neighbours oraz przedstawienie wyników działania algorytmu na danych testowych w postaci wizualizacji graficznych za pomocą biblioteki matplotlib. W ramach realizacji celu projekt obejmie również analizę porównawczą skuteczności i czasu działania własnej implementacji w odniesieniu do wersji dostępnej w standardowych bibliotekach.

Funkcje programu

Wczytywanie danych
Program umożliwia wczytanie danych wejściowych z pliku CSV lub bezpośrednio z kodu. Dane te są następnie przetwarzane do odpowiedniego formatu dla algorytmu.

Implementacja algorytmu Nearest Neighbours
Program zawiera własną implementację algorytmu k najbliższych sąsiadów (KNN). Główne kroki algorytmu:

- Obliczanie odległości (np. euklidesowej) między punktami.
- Znajdowanie najbliższych sąsiadów dla każdego punktu testowego.
- Klasyfikacja lub przewidywanie na podstawie sąsiadów.

Wykorzystanie wersji bibliotecznej algorytmu
Program porównuje własną implementację z wersją dostępną w popularnych bibliotekach, takich jak **scikit-learn**.

Wizualizacja wyników
Wyniki działania algorytmu (np. dokładność klasyfikacji, rozkład danych) są przedstawiane w postaci wykresów przy użyciu **matplotlib**.

- Wykresy rozkładu danych i ich klasyfikacji.
- Wykres porównujący czas działania implementacji własnej i bibliotecznej.
- Wykresy analizy jakości działania algorytmu (np. macierz pomyłek).

Analiza czasowa i jakościowa
Program mierzy czas działania obu wersji algorytmu oraz dokładność ich wyników. Dane te są następnie prezentowane na wykresach porównawczych.

Obsługa parametrów algorytmu
Program umożliwia użytkownikowi zmianę parametrów, takich jak:

- Liczba sąsiadów (k).
- Euklidesowa metryka odległości.
- Podział danych na zbiór treningowy i testowy.

Wyniki testów

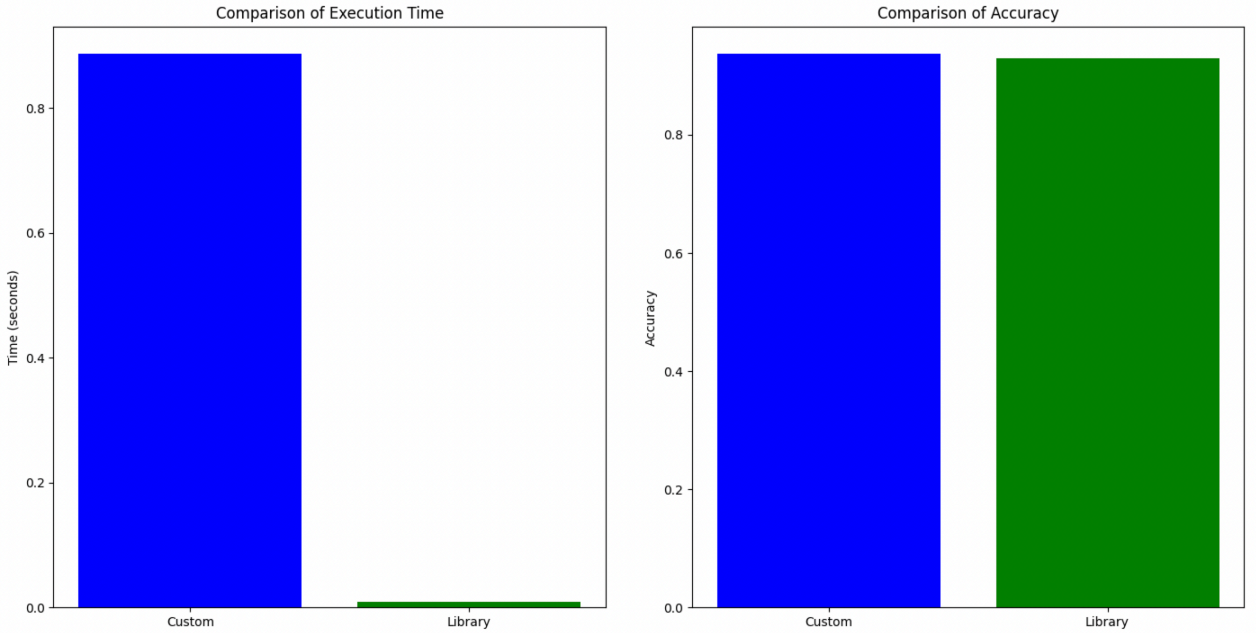

Rys 2 Porównanie czasu oraz jakości działania algorytmu

Własna implementacja:
- czas działania: 0.8 sekundy
- jakość działania: 94%

Implementacja oryginalnej biblioteki:
- czas działania: 0.008 sekundy
- jakość działania: 93%

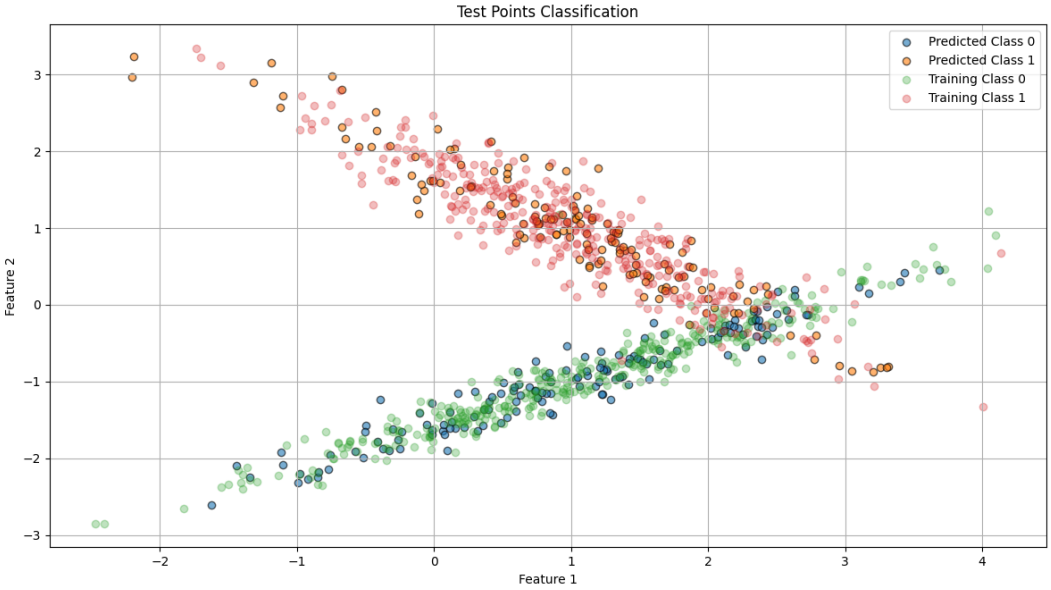

Rys 3 Klasyfikacja punktów testowych

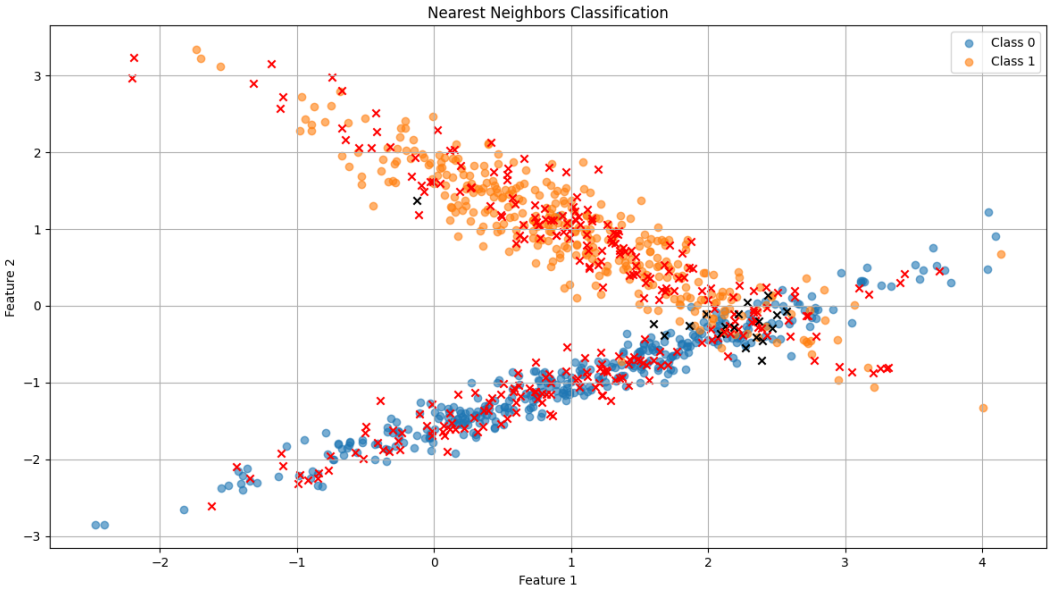

Rys 4 Przypisanie punktów do klas

Kod programu

Klasa **`NearestNeighbours`** implementuje algorytm k najbliższych sąsiadów (k-NN) do klasyfikacji danych. Konstruktor inicjalizuje wartość `k`, określającą liczbę najbliższych sąsiadów, oraz pola do przechowywania danych treningowych i ich etykiet.

- Metoda `fit` zapisuje dane treningowe i odpowiadające im etykiety w postaci tablic NumPy.
- Metoda `_euclidean_distance` oblicza odległość euklidesową między dwoma punktami.
- Metoda `predict` klasyfikuje dane testowe, iterując przez każdy punkt testowy, obliczając jego odległości do wszystkich punktów treningowych, a następnie wybierając `k` najbliższych sąsiadów.
- Najczęściej występująca etykieta wśród tych sąsiadów jest przypisywana jako wynik dla danego punktu testowego.

Funkcja **`compare_algorithms()`** porównuje działanie własnej implementacji algorytmu najbliższych sąsiadów (**Nearest Neighbours**) z wersją biblioteczną z `scikit-learn`. Najpierw generuje dane treningowe i testowe za pomocą funkcji `generate_data()`. Następnie mierzy czas wykonania i dokładność klasyfikacji dla obu wersji algorytmu. Własna implementacja wykorzystuje obiekt klasy `NearestNeighbours`, natomiast wersja biblioteczna – `KNeighborsClassifier`. Po uzyskaniu wyników funkcja wypisuje dokładność oraz czas wykonania dla obu wersji. Na końcu wizualizuje wyniki za pomocą wykresów porównujących czas wykonania i dokładność oraz wykresów przedstawiających najbliższych sąsiadów oraz klasyfikację punktów testowych.

Funkcja **`generate_data()`** generuje sztuczne dane klasyfikacyjne, a następnie dzieli je na zbiór treningowy i testowy. Oto szczegóły jej działania:

1. **Generowanie danych:**
   Używana jest funkcja `make_classification()`, która tworzy zbiór danych do klasyfikacji. Parametry:
   - `n_samples=1000`: liczba próbek wynosi 1000,
   - `n_features=2`: dane mają 2 cechy (feature),
   - `n_informative=2`: wszystkie cechy są istotne dla klasyfikacji,
   - `n_redundant=0`: brak cech redundantnych,
   - `n_clusters_per_class=1`: każda klasa jest skupiona w jednym klastrze,
   - `random_state=42`: ustawienie ziarna losowości dla powtarzalności.
2. **Podział danych:**
   Funkcja `train_test_split()` dzieli dane na zbiór treningowy i testowy:

- `test_size=0.3`: 30% danych trafi do zbioru testowego, a 70% do treningowego,
- `random_state=42`: ponownie ustawiane jest ziarno losowości.

3. **Zwracanie wyników:**
   Funkcja zwraca dane podzielone na cztery części: `X_train`, `X_test`, `y_train`, `y_test`.

Funkcja **`plot_nearest_neighbors()`** tworzy wizualizację danych treningowych i testowych, przedstawiając klasyfikację najbliższych sąsiadów.

1. **Inicjalizacja wykresu** – Ustawiany jest rozmiar wykresu (`8x8`).
2. **Rysowanie danych treningowych** – Funkcja iteruje przez unikalne etykiety (`y_train`). Dla każdej klasy wybiera odpowiednie punkty z `X_train` i rysuje je na wykresie jako punkty o różnym kolorze z etykietą klasy.
3. **Rysowanie danych testowych** – Model dokonuje predykcji dla danych testowych `X_test`. Następnie każdy punkt testowy jest rysowany na wykresie:
   - Jeśli predykcja dla danego punktu jest poprawna (zgodna z `y_test`), punkt jest zaznaczony na czerwono (`'red'`).
   - Jeśli predykcja jest błędna, punkt jest zaznaczony na czarno (`'black'`).
4. **Stylizacja wykresu** – Funkcja dodaje tytuł, opisy osi (`Feature 1` i `Feature 2`), legendę oraz siatkę, a następnie wyświetla wykres za pomocą `plt.show()`.

Wizualizacja ta pozwala łatwo zauważyć, jak model klasyfikuje punkty testowe w odniesieniu do danych treningowych.

Funkcja **`plot_test_classification()`** wizualizuje klasyfikację punktów testowych w porównaniu do danych treningowych.

1. **Inicjalizacja wykresu** – Tworzony jest wykres o rozmiarze `8x8`.
2. **Rysowanie danych testowych** – Model wykonuje predykcję dla danych `X_test`. Następnie funkcja iteruje przez unikalne etykiety klas (`y_train`), wybiera punkty testowe sklasyfikowane jako dana klasa i rysuje je na wykresie jako punkty o wyższym poziomie przezroczystości (`alpha=0.6`) i z obramowaniem (`edgecolor='k'`).
3. **Rysowanie danych treningowych** – Funkcja iteruje przez klasy i wybiera odpowiadające im punkty z danych treningowych `X_train`. Punkty te są rysowane z niższym poziomem przezroczystości (`alpha=0.3`), aby nie dominowały nad punktami testowymi.

4. **Stylizacja wykresu** – Dodawany jest tytuł, opisy osi (`Feature 1` i `Feature 2`), legenda oraz siatka. Na końcu wykres jest wyświetlany przy użyciu `plt.show()`.

Wizualizacja pozwala zobaczyć, jak model klasyfikuje dane testowe i jak te punkty są rozmieszczone względem danych treningowych.